

Báo Cáo Phân Tích Chuyên Sâu: SMOTE vs Class Weight

Báo cáo này tập trung đánh giá hiệu năng phân loại trạng thái trạm sạc xe điện (EV Charging Station Status) thông qua hai phương pháp xử lý dữ liệu mất cân bằng: 1. **Phương pháp 1 (Report 1):** Xử lý trong quá trình huấn luyện bằng tham số `class_weight="balanced"` . 2. **Phương pháp 2 (Report 3):** Tiền xử lý dữ liệu bằng kỹ thuật sinh mẫu nhân tạo SMOTE-NC (ghi ra file vật lý trước khi nạp vào mô hình).

1. Tổng quan Kết quả (Macro-F1 Score)

Chỉ số **Macro-F1** là thước đo khách quan nhất trong bài toán này vì lớp `operational` chiếm tới 81% dữ liệu.

Thuật toán	Report 1 (<code>class_weight</code>)	Report 3 (<code>SMOTE</code>)	Biến động
LSTM	0.885	0.910	📈 Tăng mạnh (+0.025)
CNN 1D	0.874	0.898	📈 Tăng mạnh (+0.024)
Random Forest	0.879	0.885	➡️ Gần như giữ nguyên
Extra Trees	0.885	0.885	➡️ Không đổi
Gaussian NB	0.646	0.810	🚀 Đột phá (+0.164)

2. Phân tích Độ nhạy với các Nhóm Thiểu số (Hard Classes)

Thách thức lớn nhất của bộ dữ liệu này là nhận diện 2 trạng thái thiểu số: `offline` (6%) và `under_maintenance` (6%).

A. Sự bứt phá của Nhóm Deep Learning (LSTM / CNN)

Khi sử dụng `class_weight`, LSTM gặp rào cản ở nhóm `under_maintenance` ($F1 = 0.718$). Tham số này chỉ phạt sai số nặng hơn chứ không cung cấp thêm **mẫu dữ liệu mới** để mạng Nơ-ron học hỏi các đặc trưng (features) đa dạng. Tuy nhiên, khi dùng **SMOTE**, thuật toán tạo ra các vector đặc trưng hoàn toàn mới (nhưng vẫn giữ được bản chất phân phối) cho lớp `under_maintenance`. Kết quả là: * $F1$ của `under_maintenance` tăng vọt từ **0.718** lên **0.795**. * $F1$ của `offline` tăng từ **0.821** lên **0.857**. * => **Kết luận:** Mạng Nơ-ron (Deep Learning) đặc biệt ưa thích dữ liệu được cân bằng vật lý (SMOTE) hơn là ép trọng số Toán học.

B. Sự "hồi sinh" của Naive Bayes

Thuật toán Naive Bayes (`gaussian_nb`) vốn không hỗ trợ sẵn tham số `class_weight`. Ở Report 1, mặc dù ta đã lách luật bằng cách ép `sample_weight` bên ngoài, thuật toán này vẫn "mù tịt" hoàn toàn với lớp `under_maintenance` ($F1 = 0.000$ - đoán sai 100%). Khi có sự trợ giúp của **SMOTE**, Naive Bayes đã lấy lại được thị lực, nâng $F1$ của nhóm này lên mức **0.520**, đẩy Macro- $F1$ tổng thể từ một con số thảm họa 0.646 lên mức chấp nhận được 0.810.

C. Tính ổn định của nhóm Cây Quyết định (Tree-based)

Các thuật toán như Random Forest hay Extra Trees tỏ ra vô cùng "lì lợm". Hiệu năng của chúng ở cả hai phương pháp đều loanh quanh mức 0.885. * **Nguyên nhân:** Bản chất các thuật toán Tree-based hoạt động dựa trên các quy tắc rẽ nhánh (if-else). Việc thay đổi `class_weight` can thiệp trực tiếp vào thuật toán tính toán Gini Impurity tại mỗi nhánh cắt, giúp Cây quyết định học cực kỳ hiệu quả mà không cần phải nhồi thêm dữ liệu giả.

3. Đánh giá Ưu & Nhược điểm (Pros & Cons)

Phương pháp 1: In-model Processing (`class_weight`)

- **Điểm mạnh (Pros):**
 - Cực kỳ tiện lợi, code ngắn gọn, không tốn thêm ổ cứng để lưu trữ file trung gian.
 - Thời gian huấn luyện nhanh vì mô hình chỉ học trên tập dữ liệu gốc (ít mẫu).
 - Hoạt động rất xuất sắc với các mô hình Tree-based.
- **Điểm yếu (Cons):**
 - Không hiệu quả tối đa với mạng Nơ-ron (Deep Learning).
 - Vô dụng với một số mô hình Toán học cổ điển không hỗ trợ trọng số.

Phương pháp 2: Pre-processing (**SMOTE**)

- **Điểm mạnh (Pros):**

- Đẩy hiệu năng mạng Deep Learning (LSTM, CNN) chạm đỉnh mới (vượt mốc 0.91).
- Phổ cập tính năng cân bằng cho TẤT CẢ các mô hình (kể cả Naive Bayes).
- Mô hình học được các biến thể phong phú hơn của dữ liệu thiểu số.
- **Điểm yếu (Cons):**
 - Làm phình to kích thước dữ liệu vật lý (từ 500KB lên hơn 2MB), tốn tài nguyên ổ cứng và RAM.
 - Làm luồng chạy (Pipeline) phức tạp hơn, bắt buộc phải có bước Align Columns để chống lỗi One-Hot Encoding như đã phân tích.
 - Thời gian train các mô hình chậm đi rõ rệt.

4. Lời khuyên Kiến trúc (Recommendation)

Nếu mục tiêu của dự án là thiết kế một API siêu nhẹ, chạy ổn định trên các server nhỏ: **Nên chọn Extra Trees + class_weight** (Tốc độ train <0.5 giây, F1 rất tốt). Nếu mục tiêu của dự án là bắt ép độ chính xác phải lên mức cực đoan nhất có thể, bất chấp tài nguyên phần cứng: **Nên chọn SMOTE + LSTM** (Macro-F1 0.910).